

# Modele Liniowe

## Powtórka do kolosa

3 grudnia 2018

### 1 Regresja liniowa

$X_i$  - zmienna objaśniająca

$Y_i$  - zmienna odpowiadająca

Model regresji:

$$Y_i = \beta_0 + \beta_1 X_i + \xi_i$$

$\beta_0$  - intercept, wyraz wolny  $\beta_1$  - nachylenie,  $\xi_i \sim N(0, \sigma^2)$  - błąd losowy

Dodatkowo:

$$E(Y_i|X_i) = \beta_0 + \beta_1 X_i$$

$$Var(Y_i|X_i) = \sigma^2$$

### 2 Estymacja

Dopasowany model regresji:

$$\hat{Y} = b_0 + b_1 X_i$$

z resztą:

$$e_i = Y_i - \hat{Y} = Y_i - (b_0 + b_1 X_i)$$

Minimalizując  $\sum e_i^2$  metodą najmniejszych kwadratów otrzymujemy wzory na estymatory  $b_0$  i  $b_1$

$$b_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2}$$

$$b_0 = \bar{Y} - b_1 \bar{X}$$

Estymator wariancji:

$$s^2 = \frac{\sum (Y_i - \hat{Y}_i)^2}{n-2} = \frac{\sum e_i^2}{n-2} = \frac{SSE}{dfE} = MSE$$

### 3 Przedziały ufności

#### 3.1 Dla $\beta_1$

$$b_1 \sim N(\beta_1, \sigma^2(b_1))$$

, gdzie

$$\sigma^2(b_1) = \frac{\sigma^2}{\sum (X_i - \bar{X})^2}$$

Statystyka testowa:

$$t = \frac{(b_1 - \beta_1)}{s(b_1)} \sim t(n-2)$$

, gdzie

$$s^2(b_1) = \frac{s^2}{\sum (X_i - \bar{X})^2}$$

Przedział ufności:

$$b_1 \pm t_c s(b_1)$$

, gdzie

$$t_c = (1 - \alpha/2, n-2)$$

##### 3.1.1 Testowanie

$$H_0 : \beta_1 = 0$$

,

$$H_a : \beta_1 \neq 0$$

odrzuć  $H_0$ , gdy  $|t| \geq t_c$

$P(|z| \geq |t|)$  - p-wartość,  $z \sim t(n-2)$

odrzuć  $H_0$ , gdy p-wartość przekracza poziom istotności

#### 3.2 Dla $\beta_0$

$$b_1 \sim N(\beta_0, \sigma^2(b_0))$$

, gdzie

$$\sigma^2(b_0) = \sigma^2 \left[ \frac{1}{n} + \frac{\bar{X}^2}{\sum (X_i - \bar{X})^2} \right]$$

Statystyka testowa:

$$t = \frac{b_0 + \beta_0}{s(b_0)} \sim t(n-2)$$

$$s^2(b_0) = s^2 \left[ \frac{1}{n} + \frac{\bar{X}^2}{\sum (X_i - \bar{X})^2} \right]$$

Przedział ufności:

$$b_0 \pm t_c s(b_0)$$

$$t_c = (1 - \alpha/2, n-2)$$

### 3.2.1 Testowanie

$$H_0 : \beta_0 = \beta_{00}$$

,

$$H_a : \beta_1 \neq \beta_{00}$$

odrzuć  $H_0$ , gdy  $|t| \geq t_c$

$$t = \frac{b_0 + \beta_{00}}{s(b_0)}$$

$P(|z| \geq |t|)$  - p-wartość ,

$$z \sim t(n-2)$$

odrzuć  $H_0$ , gdy p-wartość przekracza poziom istotności

### 3.3 Inne

Normalność  $b_0$  i  $b_1$  wynika z tego, że  $b_0$  i  $b_1$  są kombinacją liniową  $Y_i$  (iid). Jeśli  $\xi_i$  nie są z rozkładu normalnego, ale zbliżonego to można stosować z powodzeniem powyższe testy i przedziały ufności.

## 4 Moc

Moc testu (moc statystyczna) to prawdopodobieństwo niepopelnienia błędu drugiego rodzaju – przyjęcia hipotezy zerowej, gdy w rzeczywistości jest ona fałszywa. Im większe jest to prawdopodobieństwo, tym lepszy jest dany test jako narzędzie do różnicowania między hipotezą prawdziwą i fałszywą. Moc można wyrazić jako dopełnienie prawdopodobieństwa popelnienia błędu drugiego rodzaju ( $\beta$ ), czyli  $1 - \beta$ .

$$H_0 : \beta_1 = 0$$

,

$$H_a : \beta_1 \neq 0$$

Statystyka testowa:

$$t = \frac{b_1}{s(b_1)} \sim t(n-2, \delta)$$

$$\delta = \frac{\beta_1}{\sigma(b_1)}$$

$b_1 \sim N(\beta_1, \sigma^2(b_1))$  - parametr niecentralności

Musimy znać  $\sigma$ ,  $SSX$  i  $n$ , żeby obliczyć:

$$\sigma^2(b_1) = \frac{\sigma^2}{\sum (X_i - \bar{X})^2}$$

## 5 Estymacja średniej

$$E(Y_h) = \mu_h = \beta_0 + \beta_1 X_h$$

$$\hat{\mu}_h = b_0 + b_1 X_h$$

$$\hat{\mu}_h \sim N(\mu_h, \sigma^2)$$

$$\sigma^2(\hat{\mu}_h) = \sigma^2 \left[ \frac{1}{n} + \frac{(X_h - \bar{X})^2}{\sum (X_i - \bar{X})^2} \right]$$

$$s^2(\hat{\mu}_h) = s^2 \left[ \frac{1}{n} + \frac{(X_h - \bar{X})^2}{\sum (X_i - \bar{X})^2} \right]$$

$$\frac{\hat{\mu}_h - E(Y_h)}{s(\hat{\mu}_h)} \sim t(n-2)$$

### 5.1 Przedział ufności

$$\hat{\mu}_h \pm t_c s(\hat{\mu}_h)$$

## 6 Prognoza

$$Y_h = \beta_0 + \beta_1 X_h + \xi_h$$

$$s^2(pred) = s^2 \left[ 1 + \frac{1}{n} + \frac{(X_h - \bar{X})^2}{\sum (X_i - \bar{X})^2} \right]$$

$$\frac{Y_h - \hat{\mu}_h}{s(pred)} \sim t(n-2)$$

### 6.1 Przedział prognozy

$$\hat{\mu}_h \pm t_{cs}(pred)$$

## 7 ANOVA

### 7.1 Ogólnie - Total

$$SST = \sum (Y_i - \bar{Y})^2$$

$$dfT = n - 1$$

$$MST = \frac{SST}{dfT}$$

### 7.2 Model

$$SSM = \sum (\hat{Y}_i - \bar{Y})^2$$

$$dfM = 1$$

$$MSM = \frac{SSM}{dfM}$$

### 7.3 Błąd - Error

$$SSE = \sum (Y_i - \hat{Y}_i)^2$$

$$dfE = n - 2$$

$$MSE = \frac{SSE}{dfE}$$